本文档为实验指导书的补充说明，请同学们优先仔细阅读实验指导书

实验一

词法分析

词法分析的目的是读入外部的字符流（源程序）对其进行扫描，把它们组成有意义的词素序列，对于每个词素，词法分析器都会产生词法单元(Token) 作为输出

语法分析

1. SysY 文法

我们对 SysY 文法进行了一定的限制以减少难度，主要改变是同学们不需要支持二维以上的数组解析、不需要支持各种形式的浮点数字面量解析(不需要支持即我们在测试中不会出现这样的用例)，并对左递归文法做了处理。新的文法请参考 文法定义。请注意，实现必须以该文法为准

实验一大致分为两个步骤，词法分析：先将文本解析成词法单元序列，语法分析：再将词法单元序列解析成抽象语法树。

数据结构与算法

词法分析相关数据结构

Token(词法单元)

1. Token

Token 的定义在 token.h 中，同时 Token 类型的枚举类 **TokenType** 也定义在其中

```
struct Token {
    TokenType type;
    string value;
};

enum class TokenType{
    IDENFR,          // identifier
    INTLTR,             // int literal
    FLOATLTR,         // float literal
    CONSTTK,         // const
    VOIDTK,             // void
    ...
}
```

其中 **string** value 是 Token 所代表的字符串， **TokenType** type 是指 Token 的类型

```cpp
    // enumerate for Token type
    enum class TokenType
    {
        IDENFR,     // identifier
        INTLTR,     // int literal
        FLOATLTR,   // float literal
        CONSTTK,    // const
        VOIDTK,     // void
        INTTK,      // int
        FLOATTK,    // float
        IFTK,       // if
        ELSETK,     // else
        WHILETK,    // while
        CONTINUETK, // continue
        BREAKTK,    // break
        RETURNTK,   // return
        PLUS,       // +
        MINU,       // -
        MULT,       // *
        DIV,        // /
        MOD,        // %
        LSS,        // <
        GTR,        // >
        COLON,      // :
        ASSIGN,     // =
        SEMICN,     // ;
        COMMA,      // ,
        LPARENT,    // (
        RPARENT,    // )
        LBRACK,     // [
        RBRACK,     // ]
        LBRACE,     // {
        RBRACE,     // }
        NOT,        // !
        LEQ,        // <=
        GEQ,        // >=
        EQL,        // ==
        NEQ,        // !=
        AND,        // &&
        OR,         // ||
    };
    std::string toString(TokenType);

    struct Token
    {
        TokenType type;
        std::string value;
    };
```

`type`词法单元的类型

`value`词法单元的值

DFA(确定性有限自动机)

2. DFA

在词法分析中，我们使用确定有限状态自动机 (deterministic finite automaton, DFA) 来进行分词，对于一个给定的属于该自动机的状态和一个属于该自动机字母表 Σ 的字符，它都能根据事先给定的 转移函数 转移到下一个状态，某些转移函数会进行输出

我们需要为词法分析设计这样一个 DFA：它可以接收输入字符，进行状态改变，并在某些转移过程中输出累计接受到的字符所组成的字符串

该 DFA 中应存在五种状态，我们用枚举类 **State** 来表示

```
enum class State {
    Empty,              // space, \n, \r ...
    Ident,              // a keyword or identifier, like 'int' 'a0' 'else' ...
    IntLiteral,         // int literal, like '1' '1900', only in decimal
    FloatLiteral,       // float literal, like '0.1'
    op                  // operators and '{', '[', '(', ',' ...
};
```

我们将 DFA 及其行为的抽象为类和类方法，定义在 lexical.h 中

```
1  struct DFA
2      {
3          /**
4           * @brief constructor, set the init state to State::Empty
5           */
6          DFA();
7
8          /**
9           * @brief destructor
10          */
11         ~DFA();
12
13         // the meaning of copy and assignment for a DFA is not clear, so we do not
   allow them
14         DFA(const DFA &) = delete;            // copy constructor
15         DFA &operator=(const DFA &) = delete; // assignment
16
17         /**
18          * @brief take a char as input, change state to next state, and output a Token
   if necessary
19          * @param[in] input: the input character
20          * @param[out] buf: the output Token buffer
21          * @return  return true if a Token is produced, the buf is valid then
22          */
23         bool next(char input, Token &buf);
24
25         /**
26          * @brief reset the DFA state to begin
```

```
         */
        void reset();

    private:
        State cur_state;     // record current state of the DFA
        std::string cur_str; // record input characters
    };
```

`next()`当DFA.cur_str满足词法单元序列的匹配规则时，返回true,设置buf, 否则为false

`reset()`重置状态机

Scanner(扫描器)

3. Scanner

Scanner 是扫描器，其职责是将字符串输入转化为 Token 串，词法分析实际上就是实现一个 Scanner

Scanner 的定义在 lexical.h 中

```
struct Scanner {
    /**
     * @brief constructor
     * @param[in] filename: the input file
     */
    Scanner(std::string filename);

    /**
     * @brief run the scanner, analysis the input file and result a token stream
     * @return std::vector<Token>: the result token stream
     */
    std::vector<Token> run();

private:
    std::ifstream fin;  // the input file
};
```

```
struct Scanner
    {
        /**
         * @brief constructor
         * @param[in] filename: the input file
         */
        Scanner(std::string filename);

        /**
         * @brief destructor, close the file
         */
        ~Scanner();

        // rejcet copy and assignment
        Scanner(const Scanner &) = delete;
        Scanner &operator=(const Scanner &) = delete;
```

```
17
18          /**
19           * @brief run the scanner, analysis the input file and result a token stream
20           * @return std::vector<Token>: the result token stream
21           */
22          std::vector<Token> run();
23
24      private:
25          std::ifstream fin; // the input file
26      };
```

`fin`是C语言程序的文件输入流

`run()`执行后返回词法单元序列`std::vector<Token>`

词法分析相关算法

首先来介绍词法分析中最重要的组成部分DFA

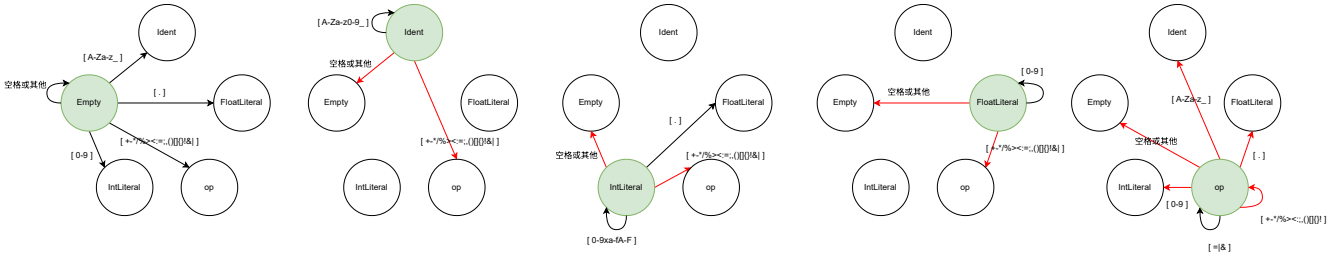

DFA类中最重要函数是DFA::next(char input, Token &buf)函数

这个函数的作用是：

1. 当DFA.cur_str满足词法单元序列的匹配规则时，返回true，供scanner类处理;
2. 当next函数返回true时，根据cur_str设置Token&buf的参数，scanner类会将buf添加进std::vector<frontend::Token> tk_stream;中

上图是一个我当时做实验写的一个简单的状态机实例。

比如对于下面这段文本

示例代码

```
1  float a =.2;
2  int b = 0x2;
3  int main(){
4      if(b==2){
5          a = 0.1;
6      }
7  }
```

有如下处理流程

input	cur_str	cur_state	return
初始	none	empty	none
f	f	ident	false
l	fl	ident	false
o	flo	ident	false
a	floa	ident	false
t	float	ident	false
空格	空格	empty	true 处理float
a	a	ident	false
空格	空格	empty	true 处理a
=	=	op	false
.	.	floatliteral	true 处理=
2	.2	floatliteral	false
;	;	op	true 处理.2

int b = 0x2;
int main(){
if(b
	.....	.....	.....

=	=	op	true 处理b
1	==	op	
2	2	intliteral	true 处理==

){
a = 0.1;
}
}
	.....	.....	.....

空格(最后一次将cur_str情空)	空格	empty	true 处理}

所以得到的输出结果为

token.value	token.type
float	FLOATTK
a	IDENT
=	ASSIGN
.2	FLOATLTR

token.value	token.type
;	SEMICN
int	INTTK
b	IDENT
=	ASSIGN
0x2	INTLTR
int	INTTK
main	IDENT
(	LPARENT
)	RPARENT
{	LBRACE
if	RBRACK
(	LPARENT
b	IDENT
==	EQL
2	INTLTR
)	RPARENT
{	LBRACE
a	IDENT
=	ASSIGN
0.1	FLOATLTR
;	SEMICN
}	RBRACE
}	RBRACE

🧠补充说明

1.这里没有考虑注释的情况，如果出现`//注释`和`/*多行注释*/`的情况下怎么办?

2.有限自动机也是正则表达式算法的核心实现，这里的程序是否能使用正则表达式来重构?

语法分析相关数据结构

AST(抽象语法树)

```
enum class NodeType {
    TERMINAL,  // terminal lexical unit
    COMPUINT,
    DECL,
    FUNCDEF,
    CONSTDECL,
    BTYPE,
    CONSTDEF,
    CONSTINITVAL,
    VARDECL,
    VARDEF,
    INITVAL,
    FUNCTYPE,
    FUNCFPARAM,
    FUNCFPARAMS,
    BLOCK,
    BLOCKITEM,
    STMT,
    EXP,
    COND,
    LVAL,
    NUMBER,
    PRIMARYEXP,
    UNARYEXP,
    UNARYOP,
    FUNCRPARAMS,
    MULEXP,
    ADDEXP,
    RELEXP,
    EQEXP,
    LANDEXP,
    LOREXP,
    CONSTEXP,
};
std::string toString(NodeType);

struct Varient
{
    Type t;
    Operand v_int;
    Operand v_float;
};

// tree node basic class
struct AstNode
{
    NodeType type;              // the node type
    AstNode* parent;            // the parent node
```

```
    vector<AstNode*> children;  // children of node

    /**
     * @brief constructor
     */
    AstNode(NodeType t, AstNode* p = nullptr);

    /**
     * @brief destructor
     */
    virtual ~AstNode();

    /**
     * @brief Get the json output object
     * @param root: a Json::Value buffer, should be initialized before calling
     * this function
     */
    void get_json_output(Json::Value& root) const;

    // rejcet copy and assignment
    AstNode(const AstNode&)            = delete;
    AstNode& operator=(const AstNode&) = delete;
};
```

`type`抽象语法树节点类型

`parent`父母节点

`children`子节点

`get_json_output`获取json形式的抽象语法树输出

Parser(语法分析器)

```
struct Parser
{
    uint32_t                  index;  // current token index
    const std::vector<Token>& token_stream;

    /**
     * @brief constructor
     * @param tokens: the input token_stream
     */
    Parser(const std::vector<Token>& tokens);

    /**
     * @brief destructor
     */
    ~Parser();

    /**
     * @brief creat the abstract syntax tree
     * @return the root of abstract syntax tree
```

```
     */
    CompUnit* get_abstract_syntax_tree();
    /**
     * @brief for debug, should be called in the beginning of recursive descent
     * functions
     * @param node: current parsing node
     */
    void log(AstNode* node);

    bool parseTerm(AstNode* root, TokenType expect);
    bool parseCompUnit(AstNode* root);
    bool parseDecl(AstNode* root);
    bool parseFuncDef(AstNode* root);
    bool parseConstDecl(AstNode* root);
    bool parseBType(AstNode* root);
    bool parseConstDef(AstNode* root);
    bool parseConstInitVal(AstNode* root);
    bool parseVarDecl(AstNode* root);
    bool parseVarDef(AstNode* root);
    bool parseInitVal(AstNode* root);
    bool parseFuncType(AstNode* root);
    bool parseFuncFParam(AstNode* root);
    bool parseFuncFParams(AstNode* root);
    bool parseBlock(AstNode* root);
    bool parseBlockItem(AstNode* root);
    bool parseStmt(AstNode* root);
    bool parseExp(AstNode* root);
    bool parseCond(AstNode* root);
    bool parseLVal(AstNode* root);
    bool parseNumber(AstNode* root);
    bool parsePrimaryExp(AstNode* root);
    bool parseUnaryExp(AstNode* root);
    bool parseUnaryOp(AstNode* root);
    bool parseFuncRParams(AstNode* root);
    bool parseMulExp(AstNode* root);
    bool parseAddExp(AstNode* root);
    bool parseRelExp(AstNode* root);
    bool parseEqExp(AstNode* root);
    bool parseLAndExp(AstNode* root);
    bool parseLOrExp(AstNode* root);
    bool parseConstExp(AstNode* root);
};
```

`index`下一个解析的词法单元

`token_stream`词法单元序列

`get_abstract_syntax_tree()`抽象语法树接口

`bool parseXXX(AstNode* root)`解析特定的抽象语法树节点，解析成功则返回true

语法分析相关算法

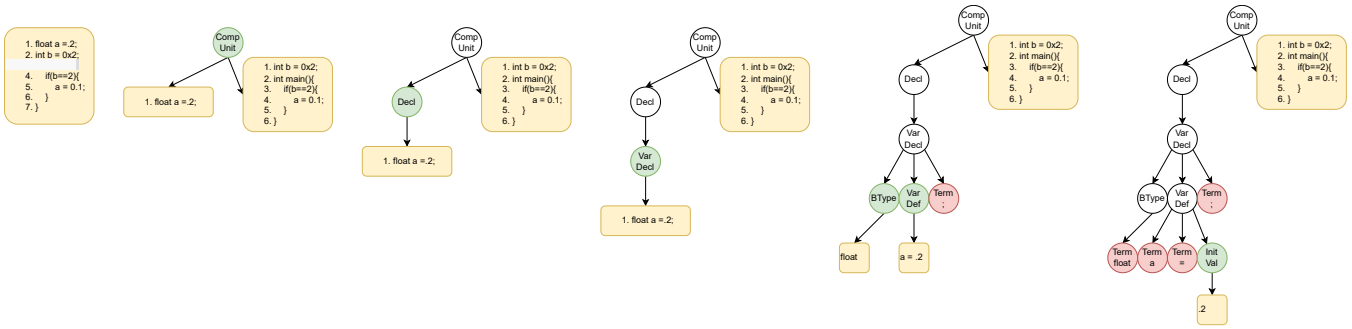

符号[...]表示方括号内包含的为可选项；

符号{...}表示花括号内包含的为可重复 0 次或多次的项；

终结符或者是单引号括起的串，或者是 Ident、InstConst、floatConst 这样的记号

产生式
CompUnit → (Decl | FuncDef) [CompUnit]
Decl → ConstDecl | VarDecl
ConstDecl → 'const' BType ConstDef { ',' ConstDef } ';'
BType → 'int' | 'float'
ConstDef → Ident { '[' ConstExp ']' } '=' ConstInitVal
ConstInitVal → ConstExp | '{' [ConstInitVal { ',' ConstInitVal }] '}'
VarDecl → BType VarDef { ',' VarDef } ';'
VarDef → Ident { '[' ConstExp ']' } ['=' InitVal]
InitVal → Exp | '{' [InitVal { ',' InitVal }] '}'
FuncDef → FuncType Ident '(' [FuncFParams] ')' Block
FuncType → 'void' | 'int' | 'float'
FuncFParam → BType Ident ['[' ']' { '[' Exp ']' }]
FuncFParams → FuncFParam { ',' FuncFParam }
Block → '{' { BlockItem } '}'
BlockItem → Decl | Stmt
Stmt → LVal '=' Exp ';' | Block | 'if' '(' Cond ')' Stmt ['else' Stmt] | 'while' '(' Cond ')' Stmt | 'break' ';' | 'continue' ';' | 'return' [Exp] ';' | [Exp] ';'
Exp → AddExp

产生式
Cond → LOrExp
LVal → Ident {'[' Exp ']'}
Number → IntConst | floatConst
PrimaryExp → '(' Exp ')' | LVal | Number
UnaryExp → PrimaryExp | Ident '(' [FuncRParams] ')' | UnaryOp UnaryExp
UnaryOp → '+' | '-' | '!'
FuncRParams → Exp { ',' Exp }
MulExp → UnaryExp { ('*' | '/' | '%') UnaryExp }
AddExp → MulExp { ('+' | '-') MulExp }
RelExp → AddExp { ('<' | '>' | '<=' | '>=') AddExp }
EqExp → RelExp { ('==' | '!=') RelExp }
LAndExp → EqExp ['&&' LAndExp]
LOrExp → LAndExp ['||' LOrExp]
ConstExp → AddExp

❗要通过实验一的检测程序**必须**按照上述产生式进行抽象语法树构建

最终我们要实现syntax.cpp文件下`get_abstract_syntax_tree()`抽象语法树接口。

⭐这部分的代码主要用到了回溯和递归的思想

`parsexxx()`函数主要做了如下两件事：

1. 当解析XXX类型节点成功时，返回true
2. 设置index在正确的位置(解析成功时为下一个词法单元索引，失败时则为解析前的词法单元索引)

示例1:产生式$A \rightarrow BC$

```
Function ParseA(ASTNode* root)
Begin
    保存index数据
    b = ParseB(第一个子节点)
    如果b为假，恢复index，返回false
    //b为真
    c = ParseC(第一个子节点)
    如果c为假，恢复index，返回false
    创建A节点，将节点的父节点设为root，将自己加入root的子节点
    返回true
End
```

示例2:产生式$A \rightarrow B|C$

```
Function ParseA(ASTNode* root)
Begin
    保存index数据
    b = ParseB(第一个子节点)
    如果b为真，创建A节点，将节点的父节点设为root，将自己加入root的子节点，返回true
    //b为假
    c = ParseC(第一个子节点)
    如果c为真，创建A节点，将节点的父节点设为root，将自己加入root的子节点，返回true
    恢复index
    返回false
End
```

示例3:产生式$A \rightarrow B\ B$ 为终结符

```
Function ParseA(ASTNode* root)
Begin
    保存index数据
    如果index对应词法单元和B不一致，恢复index，返回false
    //尝试成功
    index++
    创建Term点，将节点的父节点设为root，将自己加入root的子节点

    返回true
End
```

⭐示例4:优先级问题

对于如下一段特殊代码

```
f();
```

假设目前我们已经分析到了UnaryExp节点，对于上文定义文法如下

UnaryExp → PrimaryExp | Ident '(' [FuncRParams] ')' | UnaryOp UnaryExp

这里应该采用第二条`Ident '(' [FuncRParams] ')'`产生式。但是如果按照先后顺序分析，我们会先尝试分析`PrimaryExp`，那么它的分析路径如下：

`PrimaryExp`→`Lval`→`'f'`

分析成功，返回true，然后`ParseUnaryExp`也返回true，此时index指向的是`(`，然后程序递归到`ParseMulExp`，`ParseMulExp`尝试分析`* / %`失败，……直到所有程序都尝试解析`(`失败，程序报错。

解决方式：将第二条`Ident '(' [FuncRParams] ')'`产生式提前分析。先分析难分析的，再分析简单的，采用`贪婪模式`。

⭐示例5:另一种接口

上面提到的示例接口是

```
bool parseXXXXX(AstNode* root);
```

需要将父节点传入，供子节点使用，其实有另一种更加简便的定义接口的办法。

```
AstNode* parseXXXXX();
```

这里不需要传入父节点，而是将子节点返回给父节点，让父节点成为构建树的负责人，当构建成功时返回子节点，构建失败返回nullptr。

那么对于产生式$A \rightarrow BC$，有伪代码

```
Function ParseA(ASTNode* root)
Begin
    保存index数据
    b = ParseB(第一个子节点)
    如果b为nullptr，恢复index，返回false
    //b为真
    c = ParseC(第一个子节点)
    如果c为nullptr，恢复index，返回false
    创建a = A节点，将b,c加入自己的子节点
    返回a
End
```

Q&A